ゼミ発表

変数間の依存構造を考慮したデータ拡張

M1　齊藤光汰
2026年10月5日

本研究の問題設定

先行研究1の課題

論理崩壊データの生成

- 全体から無作為に値を抽出して補完するため
- 変数間の相関構造が無視され、非現実的な拡張データが生成される

結果として、モデルの**表現学習が阻害**される

先行研究２の課題

確証バイアスの増幅

- 文脈を維持するために疑似ラベルに依存する
- 初期の疑似ラベルを前提としてデータ拡張を行うため，疑似ラベルが誤っていた場合，ノイズが不可逆的に増幅する

テーブルデータにおける変数間の依存構造の関係を考慮したデータ拡張のフレームワークの提案

本研究の問題設定

現実の変数間の関係は、相関係数だけでは正しく捉えきれない

① 線形な関係



相関係数: ○ 検出できる

② 非線形な関係



相関係数: × 「無相関」と誤認

③ 極端な値でのみ連動



相関係数: × 見逃してしまう

相関係数(ピアソン相関)の限界

「線形な関係の強さ」しか測れない指標のため、②や③のような関係を「関係なし」と見誤り、拡張時に壊してしまう恐れがある

コピュラで捉えられること

変数の分布の形に関係なく、
①線形 ②非線形 ③極端な値どうしの連動
まで含めた依存構造を直接捉えられる

提案モデル

[第1段階]　　事前学習

データ全体の「変数間の連動ルール（非線形な相関）」をコピュラを用いて統計的に学習させる

[第2段階]　　自己教師あり学習

大量のラベルなしデータの一部をマスキングし，その値を**コピュラ**を用いて残りの変数から算出し，自然な値をサンプリングして穴埋めをする.

[第３段階]　　半教師あり学習

自己教師あり学習の事前学習済み「Encoder」をベースに、少数のラベル付きデータで予測タスクを学習。
同時に、ラベルなしデータに対してマスク適用と補完によるデータ拡張を行い、予測を安定させる

[第４段階]　　多層パーセプトロン（MLP）を使用して，最終予測をする

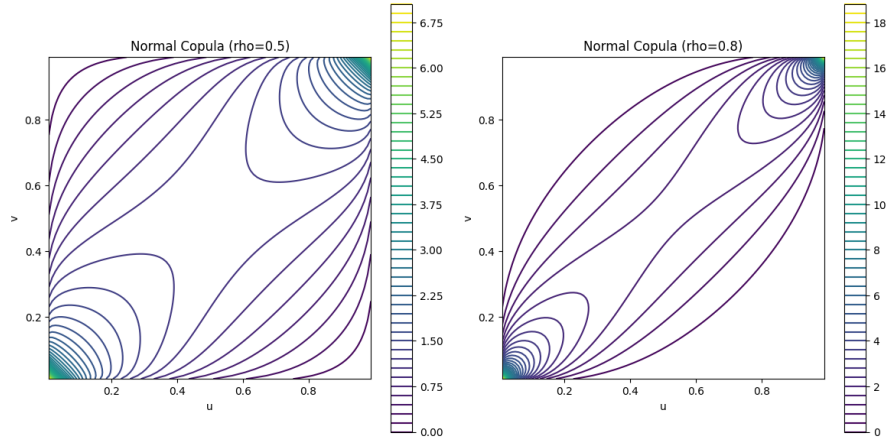
コピュラとは

各変数の分布と、変数どうしの依存を分けて表す確率モデル

例：身長の分布と体重の分布を、それぞれ別に扱う。

そのうえで「身長が高い人ほど体重も重い」といった
組合せの関係を、コピュラで表す。

本研究では、残した特徴の値に合わせて、
置換する特徴の値を生成するために使う。



分布の形と組合せの関係を、例で分けて考える

周辺分布と依存構造

以降の例はすべて、この10人の身長・体重データを用いる。

人	身長 cm	体重 kg
A	155	45
B	160	55
C	165	50
D	168	60
E	170	67
F	173	75
G	175	63
H	178	70
I	182	90
J	185	80

周辺分布
一つの列に注目した値の分布。

依存構造
同じ人の身長と体重の組合せ。

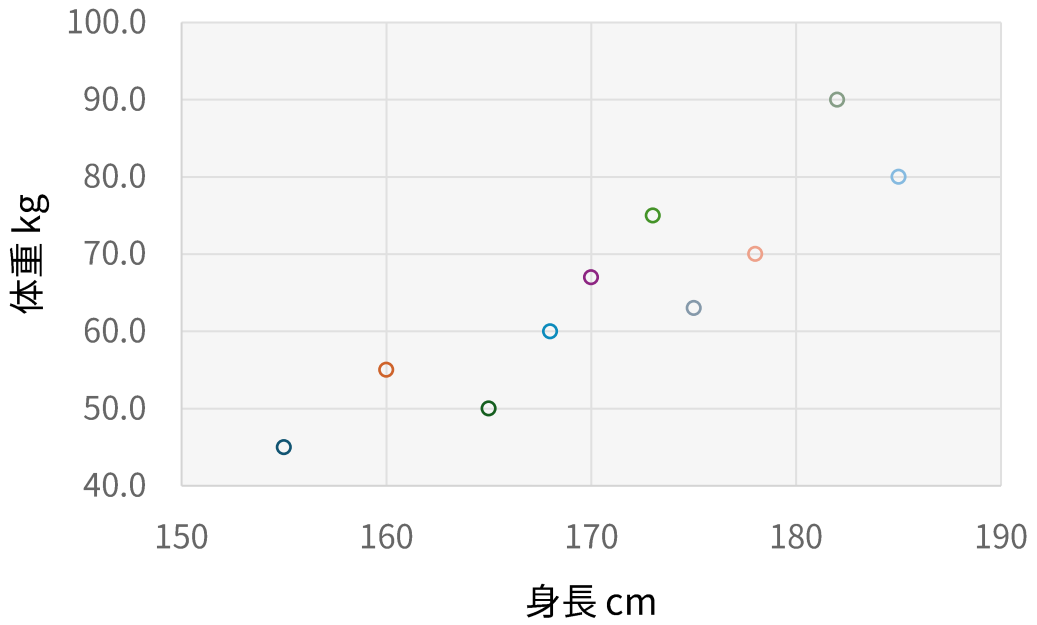
例：Hさんは178 cm、70 kg。
高い身長に必ず最も重い体重が
対応するわけではない。

同じ10人のデータで、分布・順位位置・同時確率を順に説明する

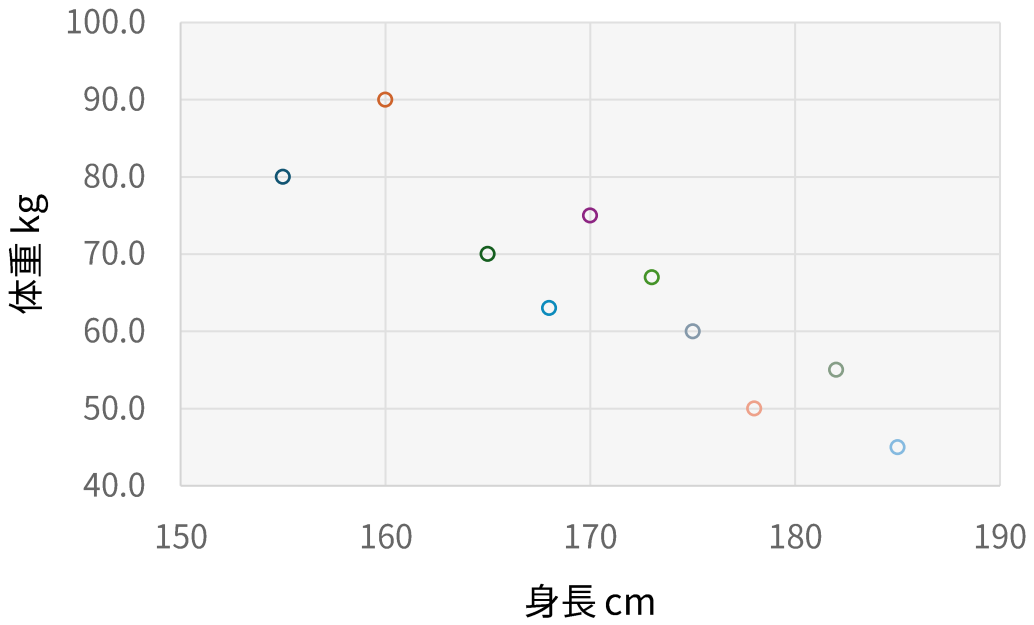
同じ周辺分布でも、依存は異なる

同じ10人の体重だけを逆順に並べ、組合せの違いを比較する。

共通データの元の組合せ



体重の対応だけを逆にした例



各列の値を変えなくても、対応を変えると依存構造は変わる

累積分布関数の意味

共通データ10人の体重を、小さい順に並べる。

人	A	C	B	D	G	E	H	F	J	I
体重 kg	45	50	55	60	63	67	70	75	80	90

累積分布関数の式

$$F_Y(70) = 70\ \text{kg以下の人数} / \text{全体人数} = 7 / 10 = 0.7$$

70 kg以下はA・C・B・D・G・E・Hの7人。
F_Yは、観測した10人から求める累積割合。

70 kgの累積確率位置は0.7。同じ計算を、身長にも適用する

確率積分変換

身長も体重も、0〜1の共通の尺度へ変換する。

確率積分変換の式（母集団の累積分布を用いる）

$$U = F_X(X),\quad V = F_Y(Y)$$

X：身長　Y：体重　U・V：分布の中の累積確率位置
連続な周辺分布なら、UとVはそれぞれ0〜1の一様分布。

元の値と確率位置の対応

各位置は「その値以下の人数 ÷ 10」で求める。

人	身長 cm	体重 kg	身長 U	体重 V
A	155	45	0.1	0.1
B	160	55	0.2	0.3
C	165	50	0.3	0.2
D	168	60	0.4	0.4
E	170	67	0.5	0.6
F	173	75	0.6	0.8
G	175	63	0.7	0.5
H	178	70	0.8	0.7
I	182	90	0.9	1.0
J	185	80	1.0	0.9

Hさん（178 cm・70 kg）の計算

身長178 cm以下は8人
$U = F_x(178) = 8 / 10 = 0.8$

体重70 kg以下は7人
$V = F_y(70) = 7 / 10 = 0.7$

Hさんの位置の組は (0.8, 0.7)。

位置は任意に付けた数ではなく、各列の累積割合から計算する

コピュラの定義式

二つの位置が、指定した範囲に同時に入る確率を表す。

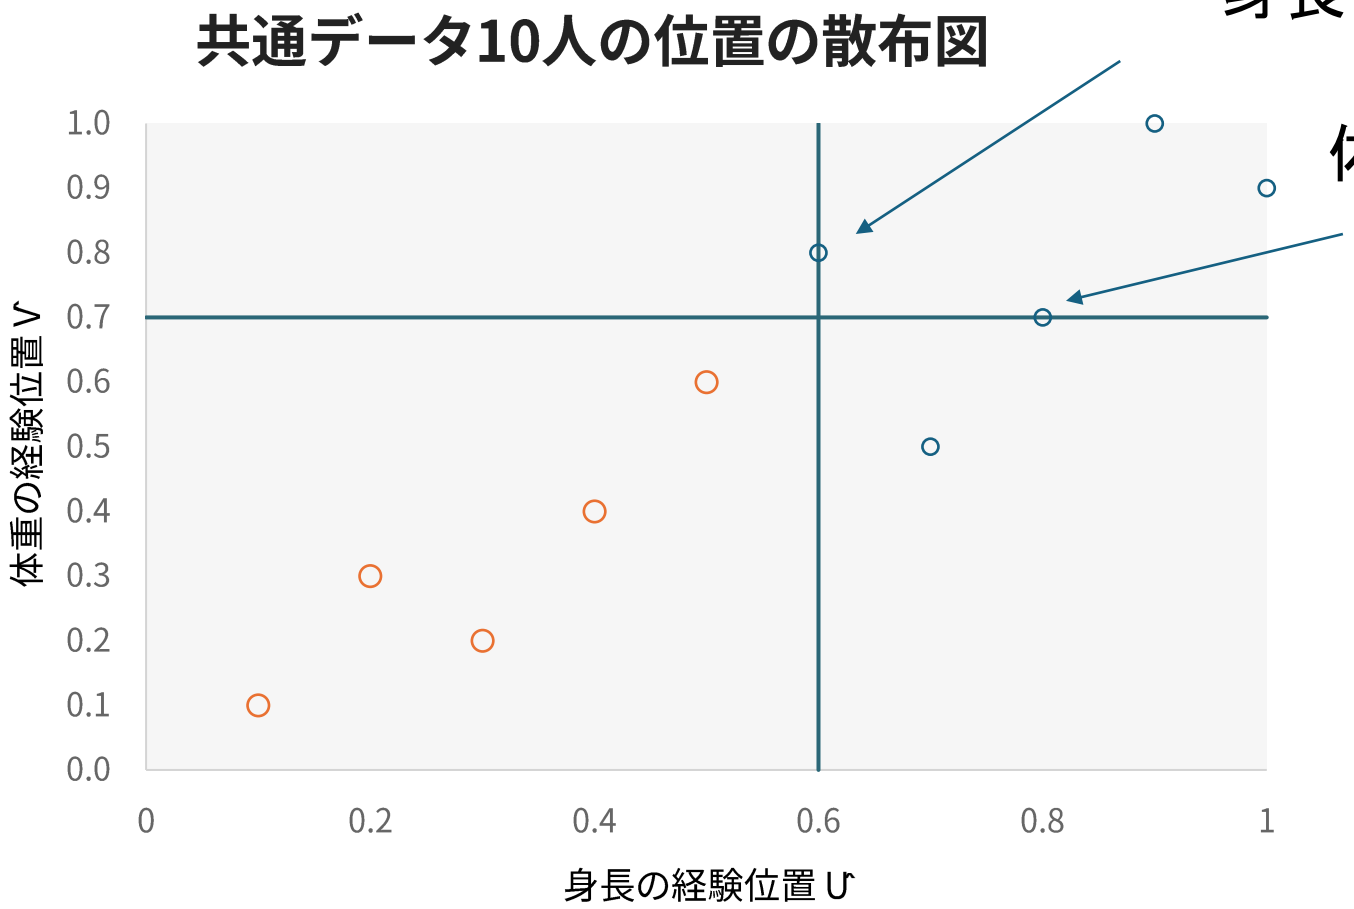
コピュラの定義：一様周辺を持つ同時累積分布関数

$$C(u, v) = P(U \leq u, V \leq v)$$

C：コピュラ　u・v：位置の上限（0〜1）

C(0.6, 0.7) は「身長の位置が0.6以下」かつ
「体重の位置が0.7以下」を同時に満たす確率。

定義式を図で読む



身長は満たしているが，体重が範囲外

体重は満たしているが，身長が範囲外

u = 0.6、v = 0.7

両条件を満たす人：
A・B・C・D・E（5人）

身長の位置0.65の生成過程

体重72 kgを残し、マスクした身長の位置を条件付きで生成する。

設定：潜在空間の相関 $\rho = 0.6$

① 体重を確率位置へ

$$v = 7 / 10 = 0.7$$

共通データ10人のうち、72 kg以下は7人。

② 正規の尺度へ変換

$$z_Y = \Phi^{-1}(0.7) \approx 0.524$$

Φ^{-1}：標準正規分布の逆累積分布関数。

③ 身長の潜在値を生成

$$z_x = \rho z_Y + \sqrt{(1 - \rho^2)}\,\varepsilon$$

$\varepsilon \sim N(0, 1)$。$\varepsilon \approx 0.0885$なら、$z_x \approx 0.315 + 0.8 \times 0.0885 \approx 0.385$。

④ 身長の位置へ戻す

$$u = \Phi(z_x) \approx \Phi(0.385) \approx 0.65$$

Φ：標準正規分布の累積分布関数。

0.65は乱数から得られる位置の一例。この後、逆変換で約174.7 cmへ戻す。

実際の生成ではεを乱数で引くため、身長の位置uは毎回変わる。

コピュラを用いた条件付き生成

値を位置へ変え、依存モデルで条件付けしてから、元へ戻す。

段階	体重70 kgを残し、身長を生成する例
条件を位置へ変換	$v = F_Y(70) = 7 / 10 = 0.7$
条件付きで位置を生成	$V = 0.7$ の条件下で、身長の位置 U を生成
元の単位へ変換	$X = F_x^{-1}(U)$ で、身長cmへ戻す

使った式：累積分布変換と逆累積分布変換。
中央の生成方法は、選ぶコピュラの種類によって変わる。

条件付きの位置の生成が、既存の無作為な列置換との違い

Gaussian copulaとStudent-t copula

変換した空間で多変量分布を用いるコピュラ。

Gaussian copula（ガウシアン・コピュラ）の式

$$C\rho(u, v) = \Phi\rho(\Phi^{-1}(u), \Phi^{-1}(v))$$

Φ：標準正規CDF　Φ^{-1}：位置を正規の値に戻す逆CDF
Φρ：相関ρを持つ二変量標準正規CDF。ρで依存を表す。

Student-t copula
正規分布の代わりにt分布を使う。上下両側の極端な値が
同時に出る依存を表せる。相関に加え自由度の推定が必要。

Gaussianは条件付き計算が容易。Student-tは両側の裾依存を扱える

使用するデータ

scikit-learnに付属する、数値特徴の分類データ。

項目	Breast Cancer	Wine
行数 / 特徴数	569行 / 30特徴	178行 / 13特徴
データの内容	細胞核の大きさ・形状など 画像から求めた数値特徴	アルコール・酸・色など ワインの化学分析値
分類ラベル	悪性 / 良性（2クラス）	ワインの品種（3クラス）
型	数値特徴	数値特徴

ラベルは分類の正解。コピュラの依存推定にはラベルを使わない

初期実験結果

分類性能の平均差は小さく、改善の結論には追加検証が必要。

ROC-AUC：平均 ± SD	列置換	Gaussian copula
Breast Cancer	0.970 ± 0.012	0.973 ± 0.017
Wine	0.826 ± 0.068	0.847 ± 0.130

平均差の95%区間
Breast Cancer：−0.005〜+0.011　Wine：−0.079〜+0.109

両方とも0を含む。少数データ・5回の探索的な比較。

課題

- 扱うデータによって，結果が変わる
- テーブルデータの特徴量が数値じゃなかった場合に，どう計算していくか
- 扱うコピュラ手法によって，精度が変わるのか

Appendix : Clayton・Gumbel・Joe copula

小さい側、大きい側など、特定の側で強い依存を表す。

種類	主な特徴	依存の例
Clayton	小さい値どうしの共発生 下側の裾依存	両方の指標が低い状態で 特に強く連動する
Gumbel	大きい値どうしの共発生 上側の裾依存	需要と負荷が非常に高い 状態で連動する
Joe	上側の裾依存 Gumbelとは内部の形が異なる	高い位置の共発生を 別の形でモデル化する

裾とは分布の端の領域。どちら側の共発生を重視するかで選ぶ

Appendix : Frank・Vine・ノンパラメトリック・コピュラ

依存の対称性や、変数の組ごとの違いを扱う候補。

種類・構成	特徴	推定・生成の注意点
Frank	対称な依存。上下の 裾依存係数は0	裾依存が0でも、 独立という意味ではない
Vine	二変量のコピュラを組合せ、 ペアごとに異なる依存を表す	組合せ・種類・パラメータを 選ぶ必要がある
ノンパラメトリック	特定の一族に固定せず、 データから柔軟に推定	高次元や少数データでの 推定・条件付けが課題

柔軟なモデルほど、必要なデータ量と推定の負担も検討する

Appendix ：ラベル付きデータの設定

全体を訓練80%・テスト20%に分け、訓練の30%にラベルを付ける。

区分	Breast Cancer	Wine
ラベル付き訓練	136件	42件
ラベルなし訓練	319件	100件
訓練合計	455件	142件
テスト	114件	36件

クラス比を保つ層化分割。テストデータは学習や分布推定に使わない。

「30%」は全データに対する割合ではなく、訓練データ内の割合

Appendix: 初期実験で用いるコピュラ

まずGaussian copulaを、VIMEの条件付き置換器に用いる。

選択理由：多変量の条件付き分布を計算しやすく、
既存の列置換と、同じ学習条件で比較できる。

条件付き正規分布の式（身長の潜在値を生成）

$$Z_x \mid Z_Y = z_Y \sim N(\rho z_Y, 1 - \rho^2)$$

Z_x・Z_Y：Φ^{-1}で変換した値　ρ：潜在空間の相関
N(平均, 分散)：正規分布。残した体重に平均を合わせ、ばらつきを残す。

Gaussianで依存保持と分類性能を検証し、必要に応じて他の種類へ広げる