

Tabular Data Contrastive Learning via Class-Conditioned and Feature-Correlation Based Augmentation

日本語まとめ・詳細要約 (Cui, Hosseinzadeh, Ma, Wu, Sui, Golestan, Layer 6 AI, arXiv:2404.17489, 2024)

Abstract (要旨)

対照学習 (Contrastive Learning) は、まず元データの類似ビュー (view) を作成し、データとそのビューを埋め込み空間上で近づけるモデル事前学習手法である。画像や自然言語データでは、直感的かつ効果的なドメイン特化型の拡張 (augmentation) 技術のおかげで成功を収めてきた。しかし表形式 (tabular) データの領域では、ビュー生成の主流手法は値をスワップしてテーブルの項目を破損 (corrupt) させる方法であり、これは理論的にも実効性の面でも十分とは言えない。

本論文では、この拡張技術に対するシンプルかつ強力な改善案を提案する：クラス識別情報に条件づけた破損 (class-conditioned corruption) である。具体的には、あるアンカー行の特定の項目を破損させる際、同一特徴量列の値をテーブル全体から一様にランダムサンプリングするのではなく、アンカー行と同一クラスに属すると判定された行のみからサンプリングする。半教師あり学習の設定を仮定し、テーブル全行のクラス識別情報を得るために疑似ラベリング (pseudo labeling) 技術を採用する。さらに、特徴量間の相関構造に基づいて破損させる特徴量を選択するという新しいアイデアも検討する。大規模な実験により、提案手法が表形式データの分類タスクにおいて従来の破損手法を一貫して上回ることが示された。コードはGitHubで公開されている (layer6ai-labs/Tabular-Class-Conditioned-SSL)。

1. Introduction (序論)

表形式データは最も基本的かつ広く存在するデータモダリティの一つであり、適切な学習アルゴリズムによって豊富な情報や知見を抽出できる。しかし、他の多くの分野で最も広く使われる学習アルゴリズムである深層学習は、表形式データの領域では依然として性能面で苦戦しており (Grinsztajn et al., 2022)、アルゴリズム改善の必要性が指摘されている。一方で、表形式データが大量に存在する中、各データ点に高品質なターゲットラベルを付与することは時間的・資源的コストが高い。そのため、モデル事前学習には半教師あり学習 (Yang et al., 2022) や自己教師あり学習 (Gui et al., 2023) の技術が必要とされる。

近年、対照学習 (Chen et al., 2020) は、自己教師あり・半教師あり学習の設定で頻繁に採用される非常に人気の高い事前学習技術として台頭している。対照学習は主に、生の入力データを中間的な埋め込み空間へ写像するエンコーダブロックを事前学習するために用いられ、画像・自然言語・音声・動画など様々なデータモダリティで応用され成功を収めてきた (Chen et al., 2020; Chen & He, 2021; Ma et al., 2021; Pan et al., 2021)。対照学習を行うための第一段階として、研究者は各元データ点 (しばしば「アンカー」と呼ばれる) の上に類似ビューを作り出すデータ拡張技術を設計する。そして、埋め込み空間におけるアンカーと対応するビュー間の距離指標 (コサイン類似度など) を最小化する対照損失が最適化される。古典的な対照損失の定式化では、異なるアンカーから生成されたビュー同士は埋め込み空間で明示的に遠ざけられるが、これに対する複数の変種として、非類似ペアを明示的に遠ざけない手法 (Chen & He, 2021) や、損失関数に追加の項を組み込む手法 (Ma et al., 2022) も提案されている。

当然ながら、データ拡張技術の設計は対照学習による事前学習性能にとって極めて重要である。優れたデータ拡張技術はしばしばドメイン固有の知識を組み込んでいる。画像データについては、研究者たちは元の意味的な内容を保存しつつ多様なバリエーションを持つ画像ビューをもたらす様々な拡張技術 (回転、切り抜き、色歪み、ガウシアンぼかしなど) をうまく開発してきた (Chen et al., 2020; Chen & He, 2021)。同様に、自然言語処理 (NLP) の分野でも、単語マスキング、単語置換、並べ替えなどのドメイン固有拡張技術を用

いた対照学習が成功を収めてきた (Shorten et al., 2021)。

しかし、表形式データの領域では、こうした効果的なデータ拡張技術の設計はより困難である。その理由は複数ある：

- 構造の欠如 (Lack of Structure)：表形式データは一般に、回転や並べ替えのような拡張技術に活用できる空間的・時間的構造を欠いている。
- スキーマの多様性 (Distinct Schemas)：各テーブルにおける特徴量のリストは、順序と意味論の両面で固有である。情報の組織化や表現方法はテーブルごとに大きく異なる。
- 特徴量の異質性 (Heterogeneous Features)：型・単位・値域が異なる表形式の特徴量が存在するため、あるテーブル内のある特徴量に適用可能な拡張技術が、他の特徴量には適用できないことがある。

文献における表形式データの拡張技術は主に3つのクラスに分類される：①特徴値の破損 (Feature-value Corruption; Yoon et al., 2020; Iida et al., 2021; Bahri et al., 2022; Nam et al., 2023)、②サンプル間の重み付き総和 (Inter-sample Weighted Summation; Somepalli et al., 2021; Darabi et al., 2021)、③特徴量サブセットの切り出し (Cropping Subsets of Features; Ucar et al., 2021; Wang & Sun, 2022)。この3つのクラスの中で、特徴値の破損が最も広く採用されている手法である。それでもなお、前述した表形式データの特性ゆえ、これらの拡張技術はモデル事前学習において顕著な改善を示すには至っていない。

本論文では、表形式データ拡張技術におけるこのギャップを認識し、まず特徴値破損技術に対する容易かつ強力な改善策として、破損手続きにクラス情報を組み込む手法を提案する。具体的には、アンカー行上の特徴値を破損させる際、置換値をテーブル全体から一様にサンプリングするのではなく、アンカー行と同一クラスに属する行の範囲内でサンプリングを制限する。これをクラス条件付き破損 (class-conditioned corruption) と呼ぶ。このシンプルな修正により、生成されるビューが元のアンカーと意味的により類似したものになる可能性を高め、対照学習を通じて埋め込み空間上でアンカーにより近づけて配置されるべきものとなる。半教師あり設定の下では全行のターゲット情報を持たないため、疑似ラベリング技術を採用してターゲットの推定値を得る。事前学習プロセスの間、エンコーダの訓練とターゲットの更新を反復的に行う。

クラス条件付き破損技術は、拡張済み表形式行を生成する際に「どう破損させるか (how to corrupt)」に関わる技術と位置づけられる。本論文ではさらに、破損戦略のもう一つの次元、すなわち「どこを破損させるか (where to corrupt)」についても検討する。具体的には、現行アプローチを改善するため特徴量相関を活用し、相関構造に基づいて破損対象の特徴量サブセットをサンプリングすることを試みる。これを相関ベースの特徴量マスキング (correlation-based feature masking) と呼ぶ。両方向についてOpenML-CC18データセット (Bischl et al., 2021) を用いた大規模な実験を実施した。結果は、クラス条件付き破損の改善が事前学習モデルを従来手法よりも上回る性能に押し上げる一方、相関ベースの特徴量マスキング技術については改善の具体的な証拠が示されなかったことを示唆している。

本論文で用いる数学記号について：上付き文字 $(\cdot)^T$ は行列（またはベクトル）の転置を表す。 $\|\cdot\|_2$ はベクトルのL2ノルムを表す。 $[N]$ はN以下の自然数からなる整数集合を表す。 $\lceil \cdot \rceil$ は天井関数（切り上げ整数関数）を表す。最後に、演算子 $\leftarrow$ は指定変数への代入を表す。

2. Problem Formulation & Background (問題設定と背景)

2.1 半教師あり表形式データ分類

表形式データセット $D = (D_{\text{train}}, D_{\text{test}})$ を考える。 D_{train} は N_l 件のラベル付きサンプル $\{(x_i, y_i)\}$ と N_u 件のラベルなしサンプル $\{x_i\}$ からなる訓練データであり、 D_{test} は N_t 件のラベル付きテストサンプルからなる（テストラベルはモデルに対して未知）。各サンプル入力 x_i は M 個の特徴量からなり、各特徴量はカテゴリーカルまたは数値のいずれかの型を持つ。 i 番目のサンプルの k

番目の特徴量を $x^{(k)}_i$ と表す。ラベル付き集合の各入力には、クラスラベル y_i が利用可能である。目的は、テストセット内の各入力をそのクラスに写像することで分類タスクを解くパラメータ化された写像 $f_\theta(\cdot)$ を学習することである。

本論文ではニューラルネットワークを用いて f_θ をモデル化し、 θ はネットワークパラメータに対応する。対照学習アルゴリズムに基づき、ニューラルネットワークは以下の3つの部分から構成される：①エンコーダ（パラメータ θ_e ）、②事前学習ヘッド（パラメータ θ_p ）、③分類ヘッド（パラメータ θ_c ）。したがって $\theta = \{\theta_e, \theta_p, \theta_c\}$ がモデルパラメータ空間となる。この3部構成のアーキテクチャは対照学習研究の慣例（Chen et al., 2020）に従うものであり、事前学習ヘッド θ_p は学習表現に追加の柔軟性を持たせるため事前学習段階でのみ含まれ、下流のファインチューニング段階では破棄される。

2.2 対照学習

対照学習は、下流の分類または回帰タスクにさらに用いられる埋め込み空間を学習するようモデルを事前学習するプロセスである。以下では、本論文のアプローチが適用する元来の対照学習アプローチを提示する。なお、後年提案された対照学習の変種も本論文のアプローチと議論に等しく適用可能である点に留意する。

拡張関数を $g(\cdot)$ とする。訓練セットからのアンカー x_i が与えられたとき、ビューは $\tilde{x}_i = g(x_i)$ として生成される。 $g(\cdot)$ が意味論を保存する操作であることを意図しているため、 $\tilde{x}_i$ は x_i と高い類似性を持つべきであり、したがって埋め込み空間における対応する表現も近いものであるべきである。ビュー生成後、元のデータ点および対応するビューの埋め込みを、それぞれ $z_i = f_{\theta_p}(f_{\theta_e}(x_i))$ 、 $\tilde{z}_i = f_{\theta_p}(f_{\theta_e}(\tilde{x}_i))$ として計算する。バッチサイズ N のサンプリングされた訓練バッチ $\{x_i\}_{i=1}^N$ を考えると、2つの埋め込み集合 $\{z_i\}_{i=1}^N$ と $\{\tilde{z}_i\}_{i=1}^N$ が得られる。この2つの集合を連結し、 $2N$ 個の埋め込み集合 $\{\hat{z}_i\}_{i=1}^{2N}$ が得られる（前半が $\{z_i\}$ 、後半が $\{\tilde{z}_i\}$ に対応）。任意の埋め込みペア z_i と z_j 間のコサイン類似度は $s_{ij} = \hat{z}_i^T \hat{z}_j / (\|\hat{z}_i\|_2 \|\hat{z}_j\|_2)$ と定義される。

この訓練バッチに対して対照損失は次のように定義される： $L = (1/2N) \sum_{i=1}^{2N} [-\log(e^{\langle s_{ii}, i' \rangle / \tau}) / \sum_{j=1}^{2N} 1_{[j \neq i]} e^{\langle s_{ij}, i' \rangle / \tau})]$ 。ここで $i' = (i + N) \bmod N$ は、インデックス i に対応するペア（ビューまたはアンカー）埋め込みのインデックスである。この損失を最小化することで、アンカーとビューのペアを徐々に近づけつつ、異なるペア間のアンカーとビューを遠ざけ、自明な解（すべてが同一点に収束する崩壊）を回避する。

対照損失を最小化してモデルを最適化した後、2.1節で述べた通り、事前学習ヘッド θ_p を破棄し、エンコーダ部分 θ_e を凍結し、エンコーダの出力を入力としてラベル付き訓練セット上で分類ヘッド θ_c を訓練する。

2.3 ランダム破損によるデータ拡張（既存手法）

2.2節で述べた通り、データ拡張関数 $g(\cdot)$ は事前学習プロセス全体にとって重要な要素である。文献において、表形式データに対して最も一般的な拡張技術は特徴値破損である。特徴量ごとの置換値のサンプリングと、破損対象とする特徴量サブセットのサンプリングの両方に、ランダムサンプリングが用いられてきた（Yoon et al., 2020; Iida et al., 2021; Bahri et al., 2022; Nam et al., 2023）。

破損手続きの詳細：p

を破損対象とする特徴量の割合（任意に選択可能なハイパーパラメータ）とすると、 M_p 個の特徴量が破損対象となる。破損対象の特徴量集合を M_{crpt} とする。既存文献では、各アンカーについて破損させる M_{crpt} 特徴量は M 個の特徴量からランダムに選択される。さらに、 M_{crpt} 内の各特徴量について、置換値もテーブル全体の当該特徴量列からランダムに選択される。拡張関数 $g(\cdot)$

を含む対照学習手続き全体はAlgorithm 1に記述されている（各エポックにおいて、全アンカーについて破損対象特徴量をランダム選択し、置換値もランダムサンプリングしてビューを構築し、対照損失を計算・最適化する、というループ構造。ミニバッチを各エポック内で用いることも可能）。

3. Method（手法）

本論文では、3.2節で述べる既存の表形式データ拡張手続きに対する2つの改善を正式に提案する。具体的には、各特徴量における置換値のサンプリング方法、および破損対象とする特徴量サブセットのサンプリング方法の両方について検討する。

3.1 どう破損させるか：クラス条件付き破損

まず「どう破損させるか」、すなわち各選択された特徴量を破損させるために用いる置換値の選択に焦点を当てる。対照学習において、各アンカーから生成されるビューはアンカーと意味的に近いものであるべきである。したがって、拡張関数 $g(\cdot)$

はバリエーションを生成しつつアンカーデータの意味論を保存すべきである。しかしながら、Algorithm 1に記述された既存の拡張関数は、特に破損対象の特徴量が行のクラス識別に大きく影響する場合、必ずしも意味論を保存しない。

この観点での拡張技術を改善するため、本論文ではクラス条件付き破損技術の採用を提案する。特に、アンカー内の各選択特徴量を破損させる際、アンカーと同一クラスに属する行からのみ特徴値をサンプリングする。破損に用いる行とアンカーが同一クラスに属することを保証することで、少なくとも下流の分類タスクの観点からは、それらの特徴の意味論がより類似したものになる可能性が高まる。

クラス条件付き破損プロセスにおける主な課題は、テーブル全体にわたるクラスラベルを得ることである。従来、2.2節で詳述した通り、対照学習はラベルを必要としない自己教師あり学習アプローチである。しかし、対照学習はニューラルネットワークのエンコーダモジュールを訓練し、意味的に有意味な埋め込み空間へと導く責務のみを担っており、単独で用いられることは稀である。多くの応用では、モデルがファインチューニングされる下流アプリケーションが存在し、その時点でターゲット情報が必要となる。したがって、少数のラベルセットが利用可能である半教師あり学習の仮定の方が、より現実的であり実世界の応用でより頻繁に遭遇する。半教師あり学習の下で利用可能な少数のクラスラベルが与えられているにもかかわらず、そうしたクラス情報を対照学習手続きに組み込まないことは機会損失であり、これが既存の表形式拡張アプローチの現状である。

半教師あり学習設定の下で、本論文では一般的な疑似ラベリングアプローチ（Grandvalet & Bengio, 2004）をラベルなし訓練セットのラベル取得に適用する。具体的には、まず小規模なラベル付きセット上でモデルを訓練し、その後残りのラベルなしセットに対して推論を実行する。モデルの出力はラベルなしデータの疑似ターゲットとみなされる。本論文では、この疑似ラベリングプロセスを対照学習事前学習段階に統合し、対照損失を最小化するようエンコーダを反復的に更新し、疑似ラベルに対する教師あり損失を最小化するよう分類ヘッドを更新する。Algorithm 2はこのプロセスの概要を示している（各エポックで、まずラベルなしデータに対して疑似ラベルを計算し、次に各アンカーについて破損対象特徴量をランダム選択し、同一疑似クラスに属する行の中から置換値をサンプリングしてビューを構築、対照損失を計算・最適化する。さらに一定エポック間隔 N_{up} ごとにエンコーダを凍結し、ラベル付きデータで分類ヘッドを教師あり学習により最適化する、という手続き）。

なお、拡張手続きにクラス情報を組み込む先行研究として、Darabi et al. (2021) や Wang & Sun (2022) が存在する。これら2つの手法と本節で提案する手法との主な違いは、対照学習の目的関数にある：これら2つのアプローチはいずれも教師あり対照学習の目的関数（Khosla et al., 2020）を用いており、これは式(5)に示した古典的な対照学習目的関数とは異なる。教師あり対照学習では、同一クラスに属するビューがまとめて引き寄せられるため、特にタブラーデータセットでよく見られるようにクラス数が少ない場合、粒度の粗い潜在

表現につながりやすい。

3.2 どこを破損させるか：相関ベースの特徴量マスキング

改善の第2の方向性として、「どこを破損させるか」、すなわちどの特徴量サブセットを破損対象とするかという問題を検討する。各アンカーで破損対象の特徴量サブセットをランダムに選択する代わりに、特徴量間の相関情報を組み込むことで対照学習の性能を改善できるという仮説を立てる。

相関ベースの特徴量マスキングの直感は、画像の破損との類推によってよりよく理解できる。画像の画素を特徴量とみなすと、一般に隣接する画素は相関のある特徴量であり、離れた非隣接の画素は無相関の特徴量である。文献では、画像破損はデータ拡張技術として探究されており、アンカー画像のパッチが破損させられる。この技術は、高度に相関のある特徴量サブセットを破損対象として選択することとみなせる。逆に、高度に無相関な特徴量を選択することは、画像上の疎らに位置する画素を破損させることに相当する。この戦略の背後にある理論的根拠は、各特徴量が破損させられても、相関のある特徴量は無傷のまま残っているという点に従う。破損された特徴量をその相関特徴量に基づいて再構成することを通じて、モデルは特徴量相関の知識を学習・活用するよう促され、これが下流タスクの遂行に役立つ。

特徴量相関指標の選択は自明ではない。最も直接的な選択は共分散行列の計算である。しかしこの指標には2つの欠点がある：カテゴリカル特徴量に対応できないこと、そして線形関係のモデリングに限定されることである。本論文では、より一般的で柔軟な相関指標として、XGBoostモデル（Chen & Guestrin, 2016）を学習し、特徴量重要度スコアを相関の代理指標として得る方法を採用する。具体的には、表形式データの全訓練セットが与えられたとき、各特徴量について、残りの特徴量からその特徴量を予測するXGBoostモデルを学習する（カテゴリカル特徴量には分類、数値特徴量には回帰）。そして、正規化された特徴量重要度スコアを、予測対象の特徴量に対して残りの各特徴量がどの程度相関しているかの指標として利用する。この特徴量重要度スコアに基づくサンプリング手続きの詳細な説明はAppendix

Aに委ねる。相関ベースの特徴量マスキングアプローチ全体の詳細な記述はAlgorithm 3に示されている（各特徴量について事前にXGBoostモデルを学習し特徴量重要度を収集した上で、各エポック・各アンカーについて、収集した重要度スコアに基づき破損対象特徴量サブセットをAlgorithm 4の手続きに従いサンプリングし、置換値はテーブル全体からランダムにサンプリングしてビューを構築、対照損失を計算・最適化する）。なお、Algorithm 3ではXGBoostモデルの特徴量重要度スコアをそのまま用いることで、高相関特徴量を含むサブセットが得られる。最も無相関な特徴量集合をサンプリングするには、Algorithm 3において特徴量重要度スコアの符号を反転させた値（負の値）を単純に用いればよい。

提案するクラス条件付き破損と相関ベースの特徴量マスキングは並行して実装可能な2つの改善であり、これはAlgorithm 2とAlgorithm 3を統合することに相当する。

4. Experiments（実験）

4.1 実験設定

本論文では2.1節で述べた半教師あり表形式分類タスクに焦点を当てる。対照学習アプローチを採用して事前学習済みモデルエンコーダ θ_e を得た後、分類ヘッド θ_c を訓練する。対照学習プロセス内では、Algorithm 2およびAlgorithm

3で詳述した提案拡張技術を実装する。両アプローチの有効性を検証するため、以下の手法と比較する：

- No Pre-train（事前学習なし）：エンコーダをランダム初期化した後、それを凍結し、ラベル付きデータセット上で分類ヘッドを直接訓練する。
- Conventional Corruption（従来の破損）：2.3節で紹介した従来のデータ拡張アプローチを用いて対照学習を実行する。

- Oracle Corruption（オラクル破損）：訓練セット全体にわたって正確なターゲットが利用可能であると仮定する。

なお、従来の破損ベースラインは本質的にBahri et al. (2022) のアプローチ（SCARF）に類似している。ただし、彼らの論文で指定された設定（主に早期終了の設定に起因）に従っても結果を安定的に再現できなかったため、本論文のシミュレーションで採用したハイパーパラメータは彼らの論文のものとはわずかに異なる。さらに、オラクル破損ベースラインは半教師あり学習の仮定の下では非現実的である点にも留意されたい。このベースラインは、クラス条件付き破損をデータ拡張プロセスに組み込むことで得られる性能改善の上限を示す役割を果たす。

ニューラルネットワークアーキテクチャの仕様について：エンコーダ、事前学習ヘッド、分類ヘッドの3モジュールすべてを全結合層で実装し、各隠れ層のサイズは256とする。エンコーダ（ θ_e ）には4つの隠れ層、事前学習ヘッド（ θ_p ）には1つの隠れ層と1つの出力層、分類ヘッド（ θ_c ）には1つの隠れ層と1つの出力層を用いる。各訓練段階のエポック数は、対照学習の事前学習が500エポック、下流ファインチューニングが100エポック、疑似ラベリングの反復更新が10エポック（Algorithm 2の N_{up} に対応）である。

4.2 対照損失の学習曲線と埋め込みの可視化

まず、4.1節で紹介した各拡張技術の下でのモデルの対照学習の進行、およびそこから得られる埋め込み空間について検証する。説明を単純化するため、本小節ではsklearnパッケージに収録されているシンプルな表形式分類データセット「breast

cancer（乳がん）」を用いる。式(5)で定義された対照損失の値をプロットしたところ（Figure 1）、表形式拡張プロセスにクラス情報を導入することが、生成されるビューをアンカーとより類似したものにすることを実際に促し、顕著に低い対照損失につながることが示された。具体的には、クラス条件付き手法（Ours）は従来手法（Conventional）よりも速いペースでより低い損失に到達し、その最終的な損失水準は全ラベル情報を持つオラクル手法（Oracle）の損失最適化結果とほぼ一致する。

続いて、各手法の下で学習された埋め込み空間を可視化する。対照学習の事前学習後、エンコーダによって計算された埋め込み $f_{\theta_e}(x)$ を取り出し、これらの埋め込みが異なるクラス間でどのように分布しているかを可視化する。主成分分析（PCA）を適用して学習済み埋め込みを3次元に削減し、クラス識別ごとにプロットする（Figure 2：No Pre-train、Conventional、Class-Conditioned（Ours）、Oracleの4手法について、訓練データ・テストデータそれぞれで正例クラス・負例クラスの分布を3D空間で示す）。可視化から明らかなように、従来の拡張技術と比較して、提案するクラス条件付き破損アプローチは、訓練セット・テストセットの両方において、異なるクラスのデータ間により明確な分離がある埋め込み空間の学習に役立つ。したがって、そのような埋め込み空間に基づいて分類を学習・実行することがより容易になる。

4.3 クラス条件付き破損による分類性能

各手法の下流分類性能を、OpenML-CC18データセット（Bischl et al., 2021）由来の大規模な表形式データ集合にわたって評価する。4.1節に記載した訓練・評価の仕様に従う。カテゴリカル特徴量については、表形式データの表現が常に有効なエンコーディング形式に従うことを保証するため、破損ステップの後にone-hotエンコーディングを適用する。

分類精度に関する各手法間の勝敗行列 W を提示する（Figure 3）。行列の (i, j) 成分は、30個のOpenML-CC18テーブルにわたって次式で計算される比率である：手法 i が手法 j に勝ったデータセット数の合計を、手法 i が手法 j に勝つか負けたデータセット数の合計で割った値（式6）。分散が等しくないことを仮定したt検定を有意水準（p値）0.05で使い、統計的に有意な比較結果が得られたデータセットについてのみ比率を計算する。分類精度の完全な結果、およびAUROC（受信者操作特性曲線下面積）の完全な結果は、それぞれAppendix BのTable 2およびTable 3に委ねる。

比較の結果、提案するクラス条件付き破損アプローチは従来の破損手法に対して顕著な改善を示し、本アプローチはデータセットの83%で改善を達成した。さらに、オラクル手法は精度・AUROC指標の両方で他の全手法に対して優勢な性能を示しており、表形式破損プロセスにクラス識別情報を考慮することの利点をさらに裏付けている。

参考として、Table 2（分類精度）に示された個別データセットの傾向を挙げると、例えば mfeat-fourier ではNo Pre-trainの68.00%からConventionalで78.19%、Class-Conditioned (Ours) で79.22%、Oracleで81.88%へと改善が見られる。tic-tac-toe ではNo Pre-train 78.39%に対しConventional 88.22%、Ours 85.68%、Oracle 88.87%となっている。一方、cmc や analcatdata-dmft、dresses-sales のように、事前学習 (Conventional・Ours・Oracleいずれも) がNo Pre-trainを上回らない、あるいはほぼ同水準にとどまるデータセットも複数存在する。

4.4 破損ベース拡張の限界

本論文で指摘しておきたい興味深い観察の一つは、驚くべきことに、一部の表形式データセットでは、事前学習を行わない (No Pre-train) 場合の分類結果が、(オラクルを含む) 事前学習後に得られる結果よりも高くなることがある、という点である。この観察は、特定の表形式データセットについては、いかなる破損ベースの拡張を用いた対照学習であっても、本質的な限界を持つ可能性があることを示唆している。本論文の著者らは、この知見が、表形式領域においてデータ拡張のための破損が常に有益であるかどうかについてのさらなる調査を動機づけるものと考えている。

この論点を理解しやすくする一例として、OpenML-CC18データセット中の Balance Scale テーブルが挙げられる。Balance Scale テーブルでは、各行が天秤における重りとピボットまでの距離から構成される。当然ながら、重みや距離をスワップして破損させると、天秤の釣り合いが急激に変化し、物理法則に矛盾する行が生成されてしまう。ただし著者らは、こうしたケースはより複雑で現実的なデータセットにおいてはおそらく稀であることも強調している。

4.5 関連ベースの特徴量マスキングによる分類性能

関連ベースの特徴量マスキングについては、3.2節で述べた2つのバリエーション (高関連の特徴量をサンプリングする場合と、無関連の特徴量をサンプリングする場合) の両方を検討する。これらの各バリエーションを、提案するクラス条件付き破損手法と組み合わせて実験する。具体的には、クラス条件付き破損技術を伴う各特徴量マスキングアプローチについて、Algorithm 2とAlgorithm 3を統合する手続きに従う。

OpenML-CC18データセットにわたる下流分類タスクにおける、対応する手法の分類精度結果およびAUROC結果は、それぞれAppendix CのTable 4およびTable 5に示されている。結果が示す通り、表形式データを破損させる際に特徴量相関を活用することによる一貫した改善は見られない。著者らはこの理由について、OpenML-CC18における表形式データセットの入念な処理・準備の過程で、各テーブル内の冗長性の多くがすでに除去されており、その結果、特徴量集合が互いにほぼ独立し、相関をほとんど共有していないためであると考えている。再びBalance Scaleテーブルが明確な例として挙げられ、このテーブルでは各特徴量が他の全特徴量から完全に独立している。

各テーブル内の特徴量相関の強さを理解するため、著者らは各テーブルの特徴量相関値の範囲を計算し、Table 4・Table 5に提示している。この特徴量相関値の範囲は、3.2節で説明した手続きにより各テーブルについて計算された特徴量相関値の範囲である。ただし著者らは、この相関値の範囲はあくまで、あるテーブル内の完全な特徴量相関構造を記述する上での氷山の一角に過ぎないことも強調している。今後の研究の方向性として、特徴量相関構造とその強度をより適切に定量化することが挙げられ、これはこのような選択的特徴量マスキングアプローチのようなデータ拡張プロセスにも恩恵をもたらすと著者らは考えている。

本質的には、これらのベンチマークテーブルには、データ拡張プロセスで活用できるほどの有意な特徴量相関構造がそもそも存在していない。著者らは、提案する関連ベースの特徴量マスキングアプローチが、実世

界の応用でより頻繁に遭遇するような、より大規模・複雑・粗いデータセットにおいて対照学習を改善する可能性を秘めていると仮説を立てている。

5. Conclusion（結論）

本論文では、半教師あり学習設定の下で、対照学習に用いられる表形式データの破損ベース拡張アプローチにおける異なるバリエーションを探究した。具体的には、拡張されたビューとアンカー行との高い類似性を確保するため、クラス条件付き破損アプローチと相関ベースの特徴量マスキングアプローチの両方を提案した。従来の破損アプローチと比較して、著者らは破損手続きにより多くの情報——具体的には疑似ラベリングを通じて得られるクラス情報、および訓練済みXGBoostモデルを通じて得られる特徴量相関情報——を組み込むことを目指した。大規模な実験結果は、クラス条件付き破損アプローチがクラス間をより良く区別する学習済み埋め込み空間を支え、その結果として下流の分類精度に改善をもたらすことを示唆している。一方、相関ベースの特徴量マスキングアプローチは、破損対象特徴量のランダム選択と比較して一貫した改善を示すことができなかった。著者らはこれが、ベンチマークデータセットを得るための前処理段階においてすでに多くの冗長性が除去されており、その結果、特徴量集合が互いにほとんど、あるいは全く相関を共有していないことに主に起因すると仮説を立てている。著者らは、本論文が表形式データにおける効果的なデータ拡張という困難な問題に対するさらなる探究と改善に光を当てることを望んでいる。

謝辞（Acknowledgements）：著者らは、本論文における特徴量の選択的サブセット化という探究方向の一つのきっかけとなった貴重な議論とアイデアについて、同僚のGabriel Loaiza-Ganem氏に謝意を表している。

Appendix A：相関ベースの特徴量マスキングのサンプリング手続き

3.2節で述べた相関ベースの特徴量マスキングアプローチでは、各アンカー行について破損対象の特徴量サブセットが特徴量相関に条件づけてサンプリングされる。この付録ではこのサンプリング手続きの詳細が説明される。

まずAlgorithm 3で述べた通り、 M 個の特徴量を持つテーブルについて、残りの $M-1$ 個の特徴量に基づき各特徴量を予測するXGBoostモデルを学習する。これにより、 k 番目の特徴量を予測する際の j 番目の特徴量重要度を $q_k^{\wedge}(j)$ と表記される特徴量重要度値の集合 $\{q_k\}$ ($k=1,...,M$) が得られる。

これらの特徴量重要度値の集合に基づき、各アンカーについて独立に特徴量サブセットをサンプリングする。Algorithm 4では、まず相関行列 C_{corr} （対角成分は0、非対角成分は、最も相関の高い特徴量をサンプリングする場合は特徴量重要度そのもの、最も無相関な特徴量をサンプリングする場合はその負の値）を構成する。次に、インデックス集合 $[M]$ から特徴量 f_1 を一様サンプリングし、これを初期の破損対象集合 M_{crpt} とする。以降、 M_p 個に達するまで、既に選択済みの特徴量に対応する行を C_{corr} から抽出し、各列（特徴量）ごとの最小値を計算することで、既選択集合内の各特徴量と最も相関の高い（または最も無相関な）新たな特徴量を優先的に選び出す確率分布を構成し、そこから次の特徴量をサンプリングして M_{crpt} に追加する、という手続きを繰り返す。この列方向の最小値をとる操作により、既に選択された特徴量集合の各要素と最も相関する（または最も無相関である）新たな特徴量を選び出すことができる。

Appendix

B：ランダム特徴量選択下での「どう破損させるか」に関する分類精度

Table 2（分類精度）およびTable 3（AUROC）には、No-PreTrain、Random（従来のランダム破損）、Class（提案するクラス条件付き破損）、Oracleの4手法について、OpenML-CC18の30個のデータセットそれぞれにおける平均値と標準誤差（±で表記）が報告されている。いずれの手法においても、破損対象の特徴量自体はランダムに選択される（4.3節の実験に対応）。本文で述べた通り、大半のデータセットで提案するクラス条件付きアプローチが従来のランダム破損アプローチを上回る改善を示す一方、残りの多くのデータセット

では両手法がほぼ互角の性能を示している。

Appendix C：相関ベースの特徴量マスキングに関する「どこを破損させるか」の分類性能

Table 4（分類精度）およびTable 5（AUROC）には、いずれもクラス条件付き破損戦略を値のサンプリングに用いた上で、破損対象特徴量の選択方法として、ランダム特徴量選択（Random Features）、最も無相関な特徴量選択（Least Correlated）、最も相関の高い特徴量選択（Most Correlated）の3手法を比較した結果が、各データセットの特徴量相関値の範囲（Feature Correlation Value Range）とともに報告されている。4.5節で述べた通り、3手法間で一貫した優劣の傾向は見られず、特徴量相関構造を活用することによる明確な改善は確認されなかった。

参考文献について

原論文には、Bahri et al. (2022) のSCARF、Bischl et al. (2021) のOpenMLベンチマークスイート、Chen et al. (2020) のSimCLR、Chen & He (2021) のSimSiam、Chen & Guestrin (2016) のXGBoost、Grandvalet & Bengio (2004) の疑似ラベリング（エントロピー最小化による半教師あり学習）、Grinsztajn et al. (2022) の「なぜ木ベースモデルは表形式データで深層学習に勝り続けるのか」、Khosla et al. (2020) の教師あり対照学習、Somepalli et al. (2021) およびDarabi et al. (2021) のSAINT、Ucar et al. (2021) のSubTab、Wang & Sun (2022) のTransTab、Yoon et al. (2020) のVIMEなど、表形式データの自己教師あり・半教師あり学習および対照学習に関する主要な関連研究が引用されている。合計28件の参考文献が挙げられている。

※本資料は原論文（Cui et al., “Tabular Data Contrastive Learning via Class-Conditioned and Feature-Correlation Based Augmentation,” arXiv:2404.17489v2, 2024）の内容を、章・節の構成に沿って日本語で詳細に要約・翻訳したものです。Table 2～5に含まれる全30データセットの数値結果は紙面の都合上すべては転記しておらず、傾向と代表例のみを示しています。個別データセットの厳密な数値が必要な場合はお知らせください。